君正®

Magik 训练量化使用指南

Date: Feb. 2022

君正®

Magik训练量化 使用指南

Copyright© Ingenic Semiconductor Co. Ltd 2022. All rights reserved.

Release history

Date/Author	Revision		Change	
Feb.2022	1.0.1	First release		
hyu				101

Disclaimer

This documentation is provided for use with Ingenic products. No license to Ingenic property rights granted. Ingenic assumes no liability, provides no warranty either expressed or implied relatingto the usage, or intellectual property right infringement except as provided for by Ingenic Terms and Conditions of Sale.

Ingenic products are not designed for and should not be used in any medical or life sustaining or supporting equipment.

All information in this document should be treated as preliminary. Ingenic may make changes to this document without notice. Anyone relying on this documentation should contact Ingenic for the current documentation and errata.

Ingenic Semiconductor Co., Ltd.

Ingenic Headquarters, East Bldg. 14, Courtyard #10 Xibeiwang East Road, Haidian District, Beijing, China,

Tel: 86-10-56345000 Fax:86-10-56345001 Http://www.ingenic.com

目录

1 简介	
2 环境安装要求	
3 环境安装步骤	
3.1 Ubuntu	
3.2 GCC	1
3.3 Nvidia Driver	2
3.4 CUDA	
3.5 CUDNN	
3.6 Python	
3.7 Pytorch	
3.8 Torchvision	
3.9 Magik 训练插件	
3.10 其他	
4 Yolov5s 训练流程	
4.1 代码下载	
4.2 数据准备	7
4.3 网络训练	
4.4 模型测试	
5 模型转换 5.1 pt 转 onnx	10
5.2 onnx 转 bin	11
6 模型上板	
6.1 代码编译	
6.2 上板运行	
7 粉捏核对	
8 常见疑问解答	
6 市 光疑 円 胖 音	10
XV	

1 简介

本指南主要针对使用君正处理芯的 Magik 平台的新手,这里以 pytorch 框架下的 Yolov5s 的 person 为例,从环境搭建、数据准备、网络训练、模型转换到最终的上板运行进行全流程的详细介绍,旨在引导使用者熟悉 Magik 的使用方法,进行实现上板流程。

2环境安装要求

- Linux
- GCC (>=5.4.0)
- Nvidia Driver
- CUDA (>=9.0)
- CUDNN
- Python (>=3.5)
- Pytorch (>=1.3)
- Torchvision

若上述环境均已具备(版本可不做固定要求),同步给相关人员以适配环境编译对应的插件,拿到插件安装包之后可直接转到步骤 3.9。

3环境安装步骤

3.1 Ubuntu

● 装机要求: Ubuntu16.04

3.2 GCC

- 版本要求: 5.4.0
- 具体步骤
 - 1. 查看当前系统 Ubuntu 16.04 的原装 GCC 版本:

gcc -v

2. 下载:

http://ftp.gnu.org/gnu/gcc

3. 编译安装:

tar -zxvf gcc-5.4.0.tar.bz2

cd gcc-5.4.0

./contrib/download prerequisites

cd ..

mkdir gcc-build-5.4.0

cd gcc-build-5.4.0

../gcc-5.4.0/configure --enable-checking=release -enable-languages= c,c++ --disable-multilib

sudo make

sudo make install

4. 检查:

再次 gcc -v 查看版本

3.3 Nvidia Driver

- 版本要求: >= 440
- 具体步骤
 - 1. 下载驱动程序

英伟达官网地址:

http://www.nvidia.cn/Download/index.aspx?lang=cn

2. 禁用 nouveau 第三方驱动

打开编辑配置文件:

sudo gedit /etc/modprobe.d/blacklist.conf

在最后一行添加: blacklist nouveau

改好后执行命令: sudo update-initramfs -u

重启使之生效: reboot

3. 安装驱动

执行命令: lsmod | grep nouveau

禁用 X 服务: sudo /etc/init.d/lightdm stop (或者: sudo service lightdm stop)

给驱动 run 文件赋予可执行权限: sudo chmod a+x NVIDIA-Linux-x86 64-440.64.run (下载的驱动文件名)

安装: sudo /NVIDIA-Linux-x86 64-440.64.run -no-opengl-files

开启 X 服务: sudo /etc/init.d/lightdm start (或者: sudo service lightdm start) –no-opengl-files 只安装驱动文件,不安装 OpenGL 文件。这个参数最重要 –no-x-check 安装驱动时不检查 X 服务,–no-nouveau-check 安装驱动时不检查 nouveau,后面两个参数可不加。

4. 检查

重启,没有问题,输入命令: nvidia-smi 如果出现了驱动版本就表示安装成功了。

NVIDIA-SMI 440.31 Drive				Driver	Version: 440.31			CUDA Version: 10.2	
GPU Fan									Uncorr. ECC Compute M.
==== 0 0%	GeForc 35C	e GTX P8	108 10W /				:00.0 Off 11178MiB	+======== 0%	N/A Default
1 0%	GeForc 50C	e GTX P2	108 60W /				:00.0 Off 11178MiB	0%	N/A Default
2 0%	GeForc 39C	e GTX P8	108 9W /	Off 250W			:00.0 Off 11177MiB	 0%	N/A Default
3 0%	GeForc 36C						00.0 Off 11178MiB	 0% +	N/A Default
Proc GPU	esses:	PID	Type	Process	name				GPU Memory Usage

3.4 CUDA

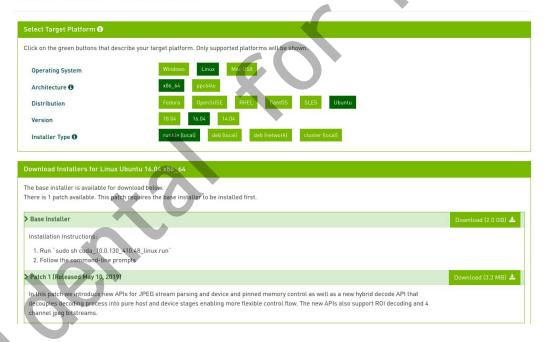
- 版本要求: 10.0
- 具体步骤
 - 1. 下载:

登录官网 https://developer.nvidia.com/cuda-10.0-download-archive?

选择 linux—x86 64—Ubuntu—16.04—runfile(local)

下载 cuda 10.0.130 410.48 linux.run

CUDA Toolkit 10.0 Archive



2. 安装:

sudo sh cuda 10.0.130 410.48 linux.run

3. 查看版本:

cat /usr/local/cuda/version.txt

4. cuda 设置(适用于多个不同版本时):

export PATH=/usr/local/cuda/bin:\$PATH

export LD_LIBRARY_PATH=

/usr/local/cuda/lib64:\$LD LIBRARY PATH

3.5 CUDNN

- 版本要求: 7.6.5
- 具体步骤
 - 1. 下载:

登陆官网: https://developer.nvidia.com/rdp/cudnn-download

选择 cuDNN Library for Linux: cudnn-10.0-linux-x64-v7.6.5.32.tgz

2. 解压:

tar -zxvf cudnn-10.0-linux-x64-v7.6.5.32.tgz

得到:

cuda/include/cudnn.h

cuda/NVIDIA SLA cuDNN Support.txt

cuda/lib64/libcudnn.so

cuda/lib64/libcudnn.so.7

cuda/lib64/libcudnn.so.7.6.5

cuda/lib64/libcudnn static.a

3. 拷贝:

sudo cp cuda/lib64/* /usr/local/cuda-10.0/lib64/

sudo cp cuda/include/* /usr/local/cuda-10.0/include/

4. 版本查看:

cat /usr/local/cuda/include/cudnn.h | grep CUDNN_MAJOR -A 2 得到:

#define CUDNN MAJOR 7

#define CUDNN MINOR 6

#define CUDNN PATCHLEVEL 5

#define CUDNN VERSION (CUDNN MAJOR * 1000 + CUDNN_MINOR

* 100 + CUDNN PATCHLEVEL)

#include "driver types.h"

3.6 Python

- 版本要求: 3.7 (注: 系统自带的 python2.7 不要卸载或删除,以免影响系统运行)
- 具体步骤:
 - 1. 下载:

wget https://www.python.org/ftp/python/3.7.3/Python-3.7.3.tar.xz

2. 编译安装:

tar -xvJf Python-3.7.3.tar.xz

cd Python-3.7.3

./configure --prefix=/usr/local/bin/python3

sudo make

sudo make install

3. 创建软链接:

In -s /usr/local/bin/python3/bin/python3 /usr/bin/python3 ln -s /usr/local/bin/python3/bin/pip3 /usr/bin/pip3 4. 版本查看:
python3 --version

3.7 Pytorch

- 版本要求: 1.3.0
- 具体步骤:
 - 1. pip 安装: pip3 install torch==1.3.0

注:这里的pip3 是上面的python3.7下的,可通过pip3 -V 查看

2. 版本查看:

python3

>> import torch

>> print(torch.__version__)

3.8 Torchvision

- 版本要求: 0.4.2
- 具体步骤:

1. pip 安装: pip3 install torchvision==0.4.2

注:这里的 pip3 是上面的 python3.7下的,可通过 pip3 -V 查看

2. 版本查看:

python3

>> import torchvision

>> print(torchyision. version)

3.9 Magik 训练插件

- 版本要求: 1.1.1
- 具体步骤:

1. 环境确认:

python

import torch

print(torch. version) #torch 的版本

print(torch.version.cuda) #对应的 cuda 版本

print(torch.backends.cudnn.version()) #对应的 cudnn 的版本

也可以根据自身需要设置 cuda 和 cudnn 的版本

2. 安装前根据上述环境在插件目录

magik-toolkit/TrainingKit/pytorch/magik whl 下找到对应的安装包

pip 安装: pip3 install magik_trainingkit_torch_130-1.1.1-py3-none-any.whl

注: 这里的 whl 安装包由我们根据客户的环境提供,如有更改,需告知相关人员同步更新。

2. 查看是否安装成功:

出现上图表明导入成功,绿色的字体中有当前使用插件的版本,commit号及编译的日期。

3.10 其他

运行 yolov5 需要一些其他的安装包:
pandas (pip install pandas)
requests (pip install requests)
cv2 (pip install opencv-python)
yaml (pip install pyyaml)
tqdm (pip install tqdm)
matplotlib (pip install matplotlib)
seaborn (pip install seaborn)
运行时如还有其他,根据提示用 pip install 进行安装,直至正常运行。

4 Yolov5s 训练流程

4.1 代码和模型的下载

yolov5 的代码地址:

https://github.com/ultralytics/yolov5.git

这里因为加入了插件部分,对相关算子进行了重新的封装,我们会提供一套基于原生 yolov5 改后的训练代码 yolov5s-person, 其中原生的算子也有做注释保留,使用者以对比修改前后的算子了解和熟悉具体修改和使用方法。若对原生的代码感兴趣,或者想先验证一下环境是否正常,也可先跑一下原生的 yolov5 的代码。

提供的代码在 magik-toolkit/Models/T40/training/pytorch/yolov5s-person 下,以下介绍的训练和转换部分均在此目录下完成。

模型的下载地址:

链接: https://pan.baidu.com/s/1LcE4-gLtGUaEplPrwt32rQ

提取码: ug3k

如图,这三个模型分别是按步骤用 coco 中的 1 万 5 的单人形(person)数据训练的 32bit,8bit 和 4bit 模型,后面的测试和上板试验用的是 yolov5s-person-4bit.pt,下载放到 magik-toolkit/Models/T40/training/pytorch/yolov5s-person/runs/train下。



4.2 数据准备

1. 以 COCO2017 为例,提取出里面的 person(id: 0)部分并转换成 Yolo 训练需要的数据格式,COCO2017 数据集下载好并解压,annotation 文件的格式为.json 格式。

下载地址(用 wget 进行下载):

图片:

http://images.cocodataset.org/zips/train2017.zip

http://images.cocodataset.org/zips/test2017.zip

http://images.cocodataset.org/zips/val2017.zip

标注:

http://images.cocodataset.org/annotations/stuff annotations trainval2017.zip

http://images.cocodataset.org/annotations/image info test2017.zip

http://images.cocodataset.org/annotations/annotations trainval2017.zip

- 2. 生成数据的脚本在 COCO for YOLO 文件夹下:
- (1)运行 python batch_split_annotation_foryolo.py (注意修改程序中的 coco 路径'coco data dir=')。
- (2)运行完会在 coco 路径下生成 person/data/images、 person/data/ImageSets、 person/data/labels 三个文件夹, 将 ImageSets 下的 train2017.txt、 val2017.txt、 test2017.txt 放入 persondet/data/coco 文件夹下, txt 文件里存储图片的绝对路径。

4.3 网络训练

1. 训练配置:

默认配置参数可参考 models/commom.py 中 is quantize, bitw, bita 等参数:

```
bita = 32

if bita==32:
    bitw = 32
    is quantize = 0
    clīp_max_value = 6.0
    shortcut_clip_max_value = 2.0

elif bita==8:
    bitw = 8
    is quantize = 1
    clīp_max_value = 6.0
    shortcut_clip_max_value = 2.0

elif bita==4:
    bitw = 4
    is quantize = 1
    clīp_max_value = 4.0
    shortcut_clip_max_value = 1.5

weight_factor = 3.0
target_device = "T40"
```

32bit, 设置: bita = 32 8bit, 设置: bita = 8 4bit, 设置: bita = 4

其中,

is_quantize - 是否进行量化, 0-不量化, 1-量化, bita 为 32 时, 注意该值设为 0

bitw - weight 的位宽 bita - feature 的位宽

clip_max_value - feature 的截断值,建议 8bit 设为 6.0,4bit 设为 4.0 shortut_clip_max_value 代表 shortcut 的 feature 的截断值,建议 8bit 设为 2.0,4bit 设为 1.5

2. 训练脚本 yolov5s-person/train.sh:

export NCCL_IB_DISABLE=1
export NCCL_DEBUG=info
GPUS=6

python3 -m torch.distributed.launch --nproc_per_node=\$GPUS

- --master_port=60051 train.py \
- --data data/coco-person.yaml\
- --cfg models/yolov5s.yaml \
- --weights ''\
- --batch-size 132 \
- --hyp data/hyp.scratch.yaml \
- --project ./runs/train/yolov5s-person-32bit \
- --epochs 300 \
- --device 0,1,2,3,4,5

(1)关于预训练

浮点训练时没有预训练模型,--weights 为'', 8bit 训练时加载已得到的精度足够的32bit 模型, 4bit 加载训练好的8bit 作为预训练模型, 这样一步步推进, 效果更佳。

(2)关于多卡训练

训练时加入了 torch.distributed.launch,为多卡的分布式训练,GPUS 的值和下面 device 的总数对应,按实际情况对应修改,如果是单卡训练,直接用python3 train.py 加上后面的参数即可。 batch-size 是所有显卡总的 batch 数目,按实际显卡大小设置即可。

(3)关于学习率

超参数的设置在 data/hyp.scratch.yaml 里, lr0 设置初始学习率, 其余采用默认值。train.py 里加载预训练模型有关于加载 optimizer 的部分, 这里因为低bit 模型相对于 32bit 模型不是接着训练而是类似重训, 所以这里建议去掉加载 optimizer 的部分, 以免影响低 bit 的训练效果。

```
# Resume
start_epoch, best_fitness = 0, 0.0
if pretrained:
    # Optimizer
    #if ckpt['optimizer'] is not None:
    # optimizer.load_state_dict(ckpt['optimizer'])
    # best_fitness = ckpt['best_fitness']

# EMA
    #if use_ema and ema and ckpt.get('ema'):
    # ema.ema.load_state_dict(ckpt['model'].float().state_dict())
# ema.updates = ckpt['updates']

# Epochs
    # start_epoch = ckpt['epoch'] + 1
    if resume:
        start_epoch = ckpt['epoch'] + 1
        assert_start_epoch > 0, '%s training to %g epochs is finished, nothing to resume.' % (wights, epochs)
```

ema 和 epoch 也存在类似的问题,因为如图也对应做了修改。

(4)模型的保存

train.py 里--project 可设置保存模型路径, 在 runs/train/project 下, weights 下保存的有两个模型,best.pt 本次训练到目前最好的, last.pt 本次训练到目前最新的, 每个 epoch 测试的结果保存在 result.txt 中, 可随时查看。

(5)训练经验

针对 yolov5 系列的训练,目前总结的经验是 32bit 用 sgd 和 lr0.01, 8bit 基于 32bit 的预训练用 sgd 和 lr0.01, 4bit 基于 8bit 的预训练用 adam 和 lr0.001。 具体命令参见 train.sh。32bit 没有预训练,收敛稍慢; 8bit 有预训练且表达能力可以,收敛较快; 4bit 虽有预训练但表达能力稍弱,收敛稍慢。

4.4 模型测试

1.待检测图片

通过 python3 detect.py -h 查看选取所需参数, 通过设置 source 可检测图片或视频或图片文件夹, 检测结果可设置显示(--view-img)或保存(--save-img)

- Image: `--source file.jpg`
- Video: `--source file.mp4`
- Directory: `--source dir/`

示例如下,若需要其他操作可选择相应的参数;

sh detect.sh(python detect.py --source data/images/bus.jpg \

--weights ./runs/train/yolov5s-person-4bit.pt \

--imgs 640 --device 0 - view-img)

其中,

source - 待检测图片

weights - 训练好的用于测试的模型

imgs - 测试图片的大小

device - 用第几块显卡测试

view-img - 是否画框显示检测结果

注: 检测的模型配置一定要和训练时候的配置(bita)一致.

2. 测试模型精度

sh test.sh(python test.py --data data/coco-person.yaml \

- --weights ./runs/train/yolov5s-person-4bit.pt \
- --imgs 640 --device 0 --batch-size 40)

待测试的模型通过---weights 指定, 验证集通过 data/coco-person.yaml 中的 val2017.txt 确定,其余参数根据实际需要给定。

具体测试结果如下:

640x640

Class Images Targets P R mAP@0.5 mAP@.5:.95

32bit: all 5000 11004 0.771 0.615 0.700 0.422

8bit: all 5000 11004 0.751 0.638 0.706 0.430

4bit: all 5000 11004 0.786 0.602 0.698 0.419

models 下的 yolov5m.yaml 和 yolov5l.yaml 也分别对应原始的 yolov5m 和 yolov5l, 训练流程也都同 yolov5s, 有需要可以直接使用。

5 模型转换

5.1 pt 转 onnx

在上述训练的环境下生成 onnx 文件:

sh convert onnx.sh(python convert onnx.py \

--weights ./runs/train/yolov5s-person-4bit.pt)

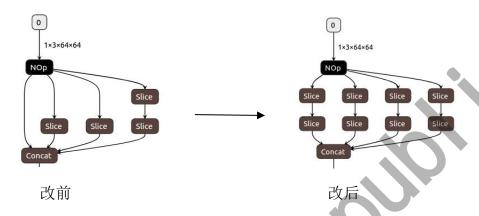
input: 指定待转模型的路径

output: .onnx, 位置和.pt 在同一目录

转 onnx 时必须使用 opset9, 否则会产生多余的节点导致后续转换工具不支持, 如因使用 opset9 转 onnx 失败, 可参见步骤 7 的疑问解答, 不同版本的 torch 会有一些不同的需要注意的点。

```
def _slice(g, input, axes, starts, ends):
    assert len(starts) == len(ends)
    # if len(starts) == 1 and starts[0] == 0 and ends[0] == 92233720368547750
    # return input
    return g.op("Slice", input, axes_i=axes, starts_i=starts, ends_i=ends)
```

特别地,对于 yolov5 用到了 focus 算子的转 onnx 之前需要注意修改 torch/onnx/symbolic opset9.py 中的 slice()函数,如下:



转换后的 onnx 文件可用 netron 进行可视化查看。

5.2 onnx 转 bin

这一步不依赖 python,torch 及插件等环境,只需要我们的转换工具 magik-transform-tools(在 magik-toolkit/TransFormKit 下)及转换脚本 run.sh:

cd transform

sh run.sh

具体地,

path=../../../../TransformKit

\$path/magik-transform-tools \

- --framework onnx \
- --target device T40 \
- --outputpath yolov5s-person-4bit.mk.h \
- --inputpath ../runs/train/yolov5s-person-4bit.onnx \
- --mean 0,0,0 \
- --var 255,255,255 \
- --img width 416 \
- --img height 416 \
- --img_channel 3

其中,

inputpath - 转换的输入,上述得到的 onnx 文件

outputpath - 转换的输出,转换完成后会保存在当前目录下生成所需的.bin 文件,这时候模型的大小才会按需求位宽减小

target device - 和训练时的设置保持一致

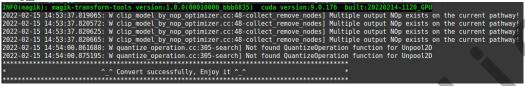
mean - 训练时的预处理的均值

var - 训练时的预处理的方差

img_width - 上板运行时的输入的宽(这里用的训练时的设置,保证 32 对齐即可)

img_height - 上板运行时的输入的宽(这里用的训练时的设置,保证 32 对 齐即可)

img channel - 上板运行时的输入的通道(和训练保持一致)



转换后会在当前目录生成 yolov5s-person-4bit.bin 文件,这个就是我们最终上板要用的二进制模型文件。

6模型上板

6.1 代码编译

1. 准备工作:

(1) mips 编译过的 pencv 库下载地址:

链接: https://pan.baidu.com/s/1Nx7yf1gzNzXCJPTTbLtvJw

提取码: 8rdl



下载之后放到 magik-toolkit/ThirdParty 下进行解压: tar -xvf opency mips 7.2.0 2.26.tar.gz

(2) yolov5s-person/venus_sample_yolov5s 目录下我们还提供了上板运行需要的 inference.cpp, Makfile、测试数据,另外我们还需要用到 venus 库及 mips 编译工具。其中,

venus 库在 magik-toolkit/InferenceKit/T40/venus 下; mips 编译工具由方案同事提供。

2. 网络输入

这里为了用户快速实现流程,我们在这里加入了 opencv 的库函数方便调用

imread 等函数,所以测试的时候直接传入 jpg 图即可。

3. 模型的加载

提供的实例 inference.cpp 中模型是通过参数传入的,运行前注意同步拷贝到板端对应的目录并在运行时传入。

4. 超参数的设置

```
pid generateBBox(std::vector<venus::Tensor> out_res, std::vector<magik::venus::ObjBbox_t>& candidate_boxes
float person_threshold = 0.3;
int classes = 1;
float nms_threshold = 0.6;
std::vector<float> strides = {8.0, 16.0, 32.0};
int box_num = 3;
std::vector<float> anchor = {10,13, 16,30, 33,23, 30,61, 62,45, 59,119, 116,90, 156,198, 373,326};
```

strides 和 anchor 按 yolov5 的实际使用设置, person_threshold 和 nms_threshold 分别对应原始代码中的 conf-thres(置信度阈值)和 iou-thres(iou 阈值), classes 是类别数。

5. 编译

TOPDIR - venus 库的相对目录

opencv_path - mips 编译后的 opencv 库的路径,拷贝也是从这里libtype - 根据实际板子的需求确定是否 muclibc(这里以 muclibc 为例)build type - release 模式,运行得到结果,默认设置

- profile 模式,运行时网络结构可视化及网络每层运行时间及 GOPs 统计
- debug 模式,运行得到结果的同时保存每层量化 feature 的结果
- nmem 模式,统计模型运行时 nmem 内存占用情况,运行程序,内存使用情况保存在/tmp/nmem_memory.txt

直接 make 编译 inference.cpp 即可生成 venus_yolov5s_bin_uclibc_*,即我们上板需要的可执行文件。

注意:我们同时提供了用于实际板端运行的输入为 nv12 的代码用例 inference_nv12.cpp 及输入数据 10_w1024_h714.nv12,如有需要,可修改 Makefile 进行编译及使用测试。

6.2 上板运行

注:

opencv 库在

magik-toolkit/ThirdParty/opencv_mips_7.2.0_2.26/uclibc/lib下 venus 库在

magik-toolkit/InferenceKit/T40/venus/7.2.0/lib/uclibc 下

1. release(发布库)

编译: make build type=release

在当前文件夹下生成 venus yolov5s bin uclibc release 可执行文件, 拷贝

venus 库(libvenus.so)、opencv 库(libopencv_core.so.3.3, libopencv_highgui.so.3.3, libopencv_imgcodecs.so.3.3, libopencv_videoio.so.3.3)、可执行文件(venus_yolov5s_bin_uclibc_release)、模型文件(yolov5s-person-4bit.bin)、测试图片(bus.jpg)至开发板运行即可: ./venus_yolov5s_bin_uclibc_release yolov5s-person-4bit.bin bus.jpg(注:运行前添加库路径至LD_LIBRARY_PATH:export LD_LIBRARY_PATH=\$lib_path:\$LD_LIBRARY_PATH).清除 make build type=release clean

```
[root@Ingenic-uc1_1:doc_test]# ./venus_yolov5s_bin_uclibc_release yolov5s-person-4bit.bin bus.jpg
Warning : The version number is not obtained. Please upgrade the soc-nna!
INFO(magik): venus version:0.9.0(00000900_86d1804) built:20220125-1052(7.2.0 mips@aie)
wi810 h:1080
pri_image w,h: 810 ,1080
model-->416 ,416 4
input shape:
-->384 640
scale---> 0.355556
resize padding over:
resize padding over:
resize valid_dst, w:288 h 384
padding info top :0 bottom 0 left:176 right:176
pad_x:176 pad_y:0 scale:0.355556
box: 50 402 224 888 0.91
box: 222 401 343 857 0.89
box: 670 388 809 883 0.84
box: 0 598 74 873 0.56
```

- 2. debug (用于核对数据的库) 详见步骤 7.2,输入的处理有些不同。
- 3. profile(网络可视化及每层运行时间统计)

编译: make build_type=profile

在当前文件夹下生成 venus_yolov5s_bin_uclibc_profile 可执行文件,拷贝 venus 库(libvenus.p.so)、opencv 库(libopencv_core.so.3.3,

libopencv_highgui.so.3.3,libopencv_imgcodecs.so.3.3,libopencv_imgproc.so.3.3, libopencv_videoio.so.3.3)、可执行文件(venus_yolov5s_bin_uclibc_profile)、模型文件(yolov5s-person-4bit.bin)、测试图片(bus.jpg)至开发板运行即可: ./venus_yolov5s_bin_uclibc_profile yolov5s-person-4bit.bin bus.jpg)注:运行前添加库路径至LD_LIBRARY_PATH:

export LD_LIBRARY_PATH=\$lib_path:\$LD_LIBRARY_PATH 清除 make build_type=profile clean

4. nmem 模式 (用于统计网络运行时 nmem 占用情况,保存在/tmp/nmem memory.txt)

编译: make build_type=nmem

在当前文件夹下生成 venus_yolov5s_bin_uclibc_nmem 可执行文件, 拷贝 venus 库(libvenus.m.so)、opencv 库(libopencv_core.so.3.3

,libopency_highgui.so.3.3,libopency_imgcodecs.so.3.3,libopency_imgproc.so.3.

3,libopencv_videoio.so.3.3)、可执行文件(venus_yolov5s_bin_uclibc_nmem)、

模型文件(yolov5s-person-4bit.bin)、测试图片(bus.jpg)至开发板运行即

可: ./venus_yolov5s_bin_uclibc_nmem yolov5s-person-4bit.bin bus.jpg

注:运行前添加库路径至LD LIBRARY PATH:

export LD_LIBRARY_PATH=\$lib_path:\$LD_LIBRARY_PATH 清除 make build type=nmem clean

```
[root@Ingenic-uc1_1:doc_test]# ./venus_yolov5s_bin_uclibc_nmem yolov5s-person-4bit.bin bus.jpg
Harning : The version number is not obtained. Please upgrade the soc-nna!
INFO(magik): venus version:0.9.0(00000900_86d1804) built:20220125-1045(7.2.0 mips@aie)
W:810 h:1080
Dri_image w,h: 810 ,1080
nodel-->416 ,416 4
input shape:
-->384 640
Scale---> 0.355556
resize padding over:
resize valid_dst, w:288 h 384
padding info top :0 bottom 0 left:176 right:176
pad_x:176 pad_y:0 scale:0.355556
pox: 50 402 224 888 0.91
pox: 222 401 343 857 0.89
pox: 670 388 809 883 0.84
pox: 0 598 74 873 0.56
[root@Ingenic-uc1_1:doc_test]# cat /tmp/nmem_memory.txt
nmem total = 131072K
nmem total = 131072K
nmem free = 118048K
#### %9.94 ####
```

7数据核对

验证 PC 端和板端的数据是否能对齐,可按如下操作:

1. PC 端

步骤 4.4-1 测试单张图片加入环境变量 MAGIK_TRAININGKIT_DUMP=1 可保存每层量化结果到/tmp/trainingkit_data/feature 下,也可通过设置环境变量 MAGIK_TRAININGKIT_PATH 指定保存的目录,具体运行命令为:

MAGIK TRAININGKIT DUMP=1

MAGIK TRAININGKIT PATH="./" python detect.py \

- --source data/images/bus.jpg \
- --weights ./runs/train/yolov5s-person-4bit.pt \
- --imgs 640 --device 0

这里的 bus.jpg 原始分辨率是 1080*810, 测试时加入了目标 imgs 为 640, 按 yolov5 代码的缩放原则(长边 640, 短边等比缩放再填充至 32 的倍数),最后进入测试的分辨率为 640*480,最终保存./trainingkit_data/feature 下(具体见下图),可见输入层有保存为 input_data_shape_1_640_480_3.bin, 后面的 shape 命名的规则是 n,h,w,c, 即高为 640, 宽为 480,最后面是三个输出层;

参数 imgs、conf-thres、iou-thres 的设置也是为了和 c 代码(详见 6.1-3)保持一致,以保证比对条件一致;

```
input data shape 1 640 480 3.bin
layer 101 QuantizeFeature.bin
layer 103 QuantizeFeature.bin
                                                                                    layer_44_QuantizeFeature.bin
layer_46_QuantizeFeature.bin
                                                                                    layer_48_QuantizeFeature.bin
layer_106_QuantizeFeature.bin
layer_108_QuantizeFeature.bin
                                                                                   layer_4 QuantizeFeature.bin
layer_56 QuantizeFeature.bin
layer_51 QuantizeFeature.bin
layer_53 QuantizeFeature.bin
layer_55 QuantizeFeature.bin
layer_56 QuantizeFeature.bin
layer_58 QuantizeFeature.bin
                                                                                    layer_4_QuantizeFeature.bin
tayer 108 QuantizeFeature.bin
layer 10 QuantizeFeature.bin
layer 110 QuantizeFeature.bin
layer 112 QuantizeFeature.bin
layer 114 QuantizeFeature.bin
layer 116 QuantizeFeature.bin
layer 110 Quantizereature.bin
layer 119 QuantizeFeature.bin
layer 121 QuantizeFeature.bin
layer 123 QuantizeFeature.bin
                                                                                    layer_60_QuantizeFeature.bin
                                                                                    layer_61_QuantizeFeature.bin
layer_63_QuantizeFeature.bin
Layer 125 QuantizeFeature.bin
Layer 127 QuantizeFeature.bin
Layer 129 QuantizeFeature.bin
                                                                                    layer_65_QuantizeFeature.bin
                                                                                    layer_67_QuantizeFeature.bin
layer_69_QuantizeFeature.bin
                                                                                    layer 6 QuantizeFeature.bin
layer 6 QuantizeFeature.bin
layer 71 QuantizeFeature.bin
layer 73 QuantizeFeature.bin
layer 75 QuantizeFeature.bin
layer 80 QuantizeFeature.bin
layer 129 Quantizereature.bin
layer 12 QuantizeFeature.bin
layer 15 QuantizeFeature.bin
layer 17 QuantizeFeature.bin
Layer_19_QuantizeFeature.bin
Layer_21_QuantizeFeature.bin
Layer_23_QuantizeFeature.bin
                                                                                     layer_82_QuantizeFeature.bin
 ayer_25_QuantizeFeature.bin
ayer_27_QuantizeFeature.bin
                                                                                    layer_84_QuantizeFeature.bin
layer_86_QuantizeFeature.bin
 ayer_28_QuantizeFeature.bin
                                                                                     layer_88_QuantizeFeature.bin
                                                                                    layer 8 QuantizeFeature.bin
layer 90 QuantizeFeature.bin
layer 93 QuantizeFeature.bin
layer 95 QuantizeFeature.bin
layer 97 QuantizeFeature.bin
            _2_QuantizeFeature.bin
_30_QuantizeFeature.bin
            _33_QuantizeFeature.bin
_35_QuantizeFeature.bin
             37_QuantizeFeature.bin
                                                                                    layer_99_QuantizeFeature.bin
             38_QuantizeFeature.bin
40 QuantizeFeature.bin
                                                                                    output_index_1_shape_1_
                                                                                                                                             80 60
                                                                                    output
```

2 板端

(1)板端需要的输入数据为 4 通道,对于上面 pc 端测试的 bus.jpg,我们用运行时保存的输入 input_data_shape_1_640_480_3.bin 处理成.h 之后拿来做板端的测试,以保证二者的输入完全一致,可先做线下处理(脚本在yolov5s-person/venus_sample_yolov5s/generate_img_input.py):

python generate_img_input.py bin_path w h c bin bin_path -- 要转换的 bin 文件,即 pc 端运行保存的输入 bin w, h -- bin 文件对应的宽和高,bin 文件名字里有对应, 分别是 1_h_w_c bin -- flag 标志,表示由 bin 文件转头文件,还有一种是 img 转头文件

说明:用 bin 的话可以完全保证两边的输入一致,方便对数据。

- (2)提供的实例中模型是通过参数传入的(argv[1]),运行时注意同步拷贝到板端对应的目录,运行时按需传入。宽(w)、高(h)也要从外部传入,具体值同(1)中。
- (3)编译 c 代码:编译之前最好先将之前编译过的模式做一下 clean(make build_type=release/profile/nmem clean),不然可能出现 opency 的链接库失败的错误,之后 make build_type=debug ,在当前文件夹下生成venus_yolov5s_bin_uclibc_debug可执行文件,拷贝 venus 库(libvenus.d.so)、可执行文件(venus_yolov5s_bin_uclibc_debug)、模型文件(yolov5s-person-4bit.bin)至开发板运行:

./venus_test_bin_uclibc_t40 yolov5s-person-4bit.bin 480 640 其中,480对应为w,640对应h,运行的时候就会自动保存每层的输出及 其他信息(如下图):

其中 layer_*_QuantizeFeature_out.bin 和 PC 端 运 行 时 保 存 在/tmp/trainingkit_data/feature下的 layer_*_QuantizeFeature.bin 是一一对应的,直接核对 md5 值是否一致即可,在保证输入完全一致的情况下中间有层不对应及时反馈。

86859cb6efb8cfd932dbb57e32a260e3 /tmp/trainingkit_data/feature/layer_2_QuantizeFeature.bin 6e2c04cf0e560cbd3b76860a23132053 /tmp/trainingkit_data/feature/layer_129_QuantizeFeature.bin

[root@Ingenic-uc1_1:doc_test]# md5sum layer_2_QuantizeFeature_out.bin 36859cb6efb8cfd932dbb57e32a260e3 layer_2_QuantizeFeature_out.bin [root@Ingenic-uc1_1:doc_test]# md5sum layer_129_QuantizeFeature_out.bin 5e2c04cf0e560cbd3b76860a23132053 layer_129_QuantizeFeature_out.bin

debug模式这里只核对网络结果,没有加后处理部分,因此无结果打印。

8 常见疑问解答

1. 问: 为什么 release 运行 810*1080 的 bus.jpg 的分辨率是 640*384, debug 的时候是 480*640?

答: 当我们设置目标分辨率为 640 时,板端的缩放规则是按等比缩放之后 w 填充至 640 (因为实际的视频流大都是 w>h),这里 640 是 w, 384 是 h; 而 yolov5 代码里的规则是按长边 640 等比缩放再将短边填充至 32 的倍数,所以这里 h 是 640,480 是 w, debug 是和 pc 端保持一致的,实际使用按需设置即可。

2. 问: 导入 magik 包出现 "undefined symbol:

_ZN6caffe28TypeMeta21_typeMetaDataInstanceIN3c108BFloat16EEEPKNS_6 detail12TypeMetaDataEv" 类似错误?

答: 当前环境下 torch 的版本和 magik 包的不对应。

3. 问: "importError: version 'libcudart.so.10.1' not found"? 答: 当前 cuda 版本和插件编译时的版本不对应

4. 问:加插件之后的网络是否可以加载原生 torch 模型做预训练? 答:理论可以,层对应好就行,不过基于原生 float 的 32bit 模型还是要再 微调训练一下,不建议直接加载原生的跑 8bit。

5. 问:训练出现"RuntimeError: Address already in use"? 答:在 python -m torch.distributed.launch 后指定一个未被使用的端口—master port=60053

6. 问:训练出现"expected scalar type Float but found Half"? 答: torch 中用了 amp.autocast 进行半精度训练加速,但量化暂不支持半精度训练,注掉这块即可。另,原生 v5 在保存模型时按 half()存的,目前发现量化这样操作最后存的模型的精度会有损失,建议去掉。

7. 问: torch 转 onnx 出现 "step!=1 is currently not supported"? 答: yolov5 slice 转换遇到的问题, 1.6 及之前版本可以可以,1.7 以后变成 error 了, torch/onnx/symbolic_opset9.py 对应报错的行 if + raise RuntimeError 注掉即可。

8. 问: torch 转 onnx 出错 "RuntimeError:input_shape_value== reshape_value || input_shape_value== 1 || reshape_value == 1 INTERNAL ASSERT FAILED ······" ?

答: 1.9 版本之后的错, torch/onnx/utils.py 中 635 行_export()最后一个参数的 onnx_shape_inference=True 改为 onnx_shape_inference=False; torch1.10 是在 677 行。不同版本找这个函数相应修改即可。

- 9. 问: torch1.8/torch1.9 版本转换 onnx 会出现"Warning: Unsupported operator NOp. No schema registered for this operator."等?答: warning 不用管,不影响结果。
- 10. 问: 转 bin 出现 "After checking the input dimension, the input of concat cannot be concatenated!"?
- 答: slice 的问题(参见 5.1),将 torch/onnx/symbolic_opset9.py 中_slice 函数中的 if+return 这两句去掉,可视化 onnx 的 slice 正常。
- 11. 问: c 代码编译出现 "error: 'constexpr bool std::isinf(double)' conflicts with a previous declaration"等一系列冲突错误?
- 答: mips 的编译器和 x86 自带的出现冲突,将环境变量CPLUS INCLUDE PATH中关于/usr/include/x86 64-linux-gnu的部分去掉。
- 12. 问: c 端编译出现"make: mips-linux-gnu-g++: Command not found"? 答: 未指定 mips 编译器,通过 export 设置。
- 13. 问: 板端精度和 PC 端精度损失有多少?
- 答:理论上损失很小,1个点以内,若出现较大差距,可检查输入是否一致,训练和验证的数据是BGR/RGB,阈值的设置,也可对比网络输出结果看看输出是否一致,具体见步骤7.
- 14. 问:转 onnx 的分辨率,转换工具的分辨率以及板端测试的分辨率需要保持一致吗?
- 答:最好保持一致,尤其后两者,本例中没有保持一致是因为对这个没有影响,对于其他非全卷积网络可能导致转换出来的模型有影响,所以测试验证集精度时建议输入数据统一线下处理到同一大小再做 PC 端和板端的比较。